

데이터 교란을 통한 대형 언어 모델의 일반화 성능 및 데이터 유출 검증

*김태민¹, *조석래¹

¹한성대학교

e-mail : taemin6697@gmail.com, cho020218@gmail.com

Evaluating Generalization and Data Leakage in Large Language Models via Data Perturbation

*TaeminKim¹ and *SeokleaCho¹

¹ Hansung University

Abstract

This study addresses the issue of data leakage in Large Language Model (LLM) evaluation and proposes a perturbation-based robustness test to assess true generalization ability. We construct semantically preserved but surface-level altered datasets by applying synonym substitution and label/schema renaming. Three recent small LLMs—Gemma-3-4b-it, Llama-3.2-3B-Instruct, and Qwen2.5-3B-Instruct—are evaluated on original and perturbed versions of AG News, IMDB, SST-2, DBpedia-14, and Titanic benchmarks. Results show that some models suffer up to 37% accuracy drops on perturbed data, revealing potential benchmark memorization, while Gemma-3-4b-it maintains stable performance, indicating stronger robustness. These findings demonstrate that conventional benchmark scores may overestimate model capability, and that perturbation-based evaluation provides a more reliable measure of LLM generalization and data leakage resilience.

I. 서론

최근 LLM(Large Language Models)은 다양한 NLP 작업에서 인간을 상회하는 괄목할 만한 성능을 달성했습니다. 특히, 별도의 미세조정없이도 프롬프트 내의 Few-shot만으로 새로운 작업을 수행하는 인-컨텍스트 러닝(In-Context Learning, ICL) 능력은 LLM의 핵심적인 역량으로 부상했습니다. 이러한 능력을 바탕으로 LLM은 텍스트 분류, 요약, 질의응답 등 광범위한 분야에서 활용되고 있으며, 모델의 성능을 측정하기 위한 표준 벤치마크 데이터의 중요성 또한 그 어느 때보다 커지고 있습니다.

이러한 강력한 범용성을 바탕으로, 텍스트 분류는 물론 정형 데이터 분류와 같은 전통적인 머신러닝 영역에서도 LLM을 적용하려는 시도가 활발히 이루어지고 있습니다. 그 결과, 이들 표준 텍스트, 정형 데이터 벤치마크를 사용한 성능 평가가 특정 테스트의 우수성을 입증하는 지표가 되었습니다. 그러나 현재 널리 사용되는 많은 텍스트 분류, 정형 데이터는 중대한 한계를 안고 있습니다. 이 데이터셋들은 웹상에 널리 공개되어 있어, LLM의 방대한 학습 데이터에 이미 포함되었을 가능성, 즉 Data Leakage 문제를 배제하기 어렵습니다. 만약 모델이 벤치마크를 학습 과정에 포함했다면, 해당 벤치마크 점수는 모델의 실제 추론 능력이나 일반화 성능을 반영하는데 부적절합니다.

본 논문에서는 이러한 벤치마크 학습 문제를 정량적으로 측정하고, LLM의 일반화 성능과 강건성을

평가하는 벤치마크 분석을 수행합니다. 우리는 모델이 데이터의 표면적 형태가 아닌, 내재된 의미를 이해하고 있는지 확인하기 위해 '데이터 교란(data perturbation)' 기법을 도입했습니다. 구체적으로, 원본 벤치마크 텍스트의 핵심 의미는 보존하되 (e.g., NLTK WordNet 기반 동의어 치환), 원본과의 문자적 일치는 깨뜨리는 방식의 '교란 데이터셋(perturbed dataset)'을 구축했습니다. 또한, 정형 데이터의 경우 컬럼명이나 타겟 클래스명을 변경하는 구조적 교란을 적용했습니다.

우리의 가설은 "만약 모델이 벤치마크 데이터를 학습했다면, 원본 데이터에서는 높은 성능을 보이다가도 의미가 동일한 교란 데이터에서는 심각한 성능 저하를 보일 것"이라는 것입니다. 이 가설을 검증하기 위해, 우리는 Gemma-3-4b-it[1], Llama-3.2-3B-Instruct[2], Qwen2.5-3B-Instruct[3] 등 최신 소형 LLM(sLLM)을 대상으로 AG News, IMDb, SST-2, DBpedia-14 (텍스트 분류) 및 Titanic (정형 데이터 분류) 벤치마크의 원본(Original)과 교란(Perturbed) 버전에서의 인-컨텍스트 러닝 성능을 비교 측정했습니다.

실험 결과, 일부 모델은 특정 벤치마크 데이터의 교란 버전에서 원본 대비 최대 -37.29%에 달하는 심각한 정확도 하락을 보였습니다. 이는 해당 모델이 이 벤치마크 데이터를 학습했을 가능성을 강력히 시사합니다. 흥미롭게도 Qwen2.5-3B[3] 모델은 SST-2에서 유사한 성능 저하(-29.29%)를 보여, 모델별로 학습한 벤치마크가 다를 수 있음을 입증했습니다. 반면, Gemma-3-4b-it[1] 모델은 대부분의 텍스트 교란 데이터에서 성능 하락이 거의 없거나 오히려 소폭 상승하여, 더 우수한 일반화 성능과 강건성을 입증했습니다.

본 연구는 표준 벤치마크 데이터 점수만으로는 LLM의 실제 능력을 파악하기 어려움을 실증적으로 보이며, 데이터 교란을 통한 강건성 테스트가 모델의 학습 여부를 판별하고 일반화된 추론 능력을 평가하는 데 필수적인 방법론임을 시사합니다.

II. 관련 연구

서론에서 제기한 벤치마크의 '데이터 유출(Data Leakage)' 문제는 최근 LLM 평가의 신뢰성을 저해하는 핵심적인 난제로 부상했으며, 이에 대한 학계의 실증적 연구가 활발히 진행되고 있습니다.

최신 연구들은 데이터 유출이 단순한 기우가 아닌, 측정 가능한 성능 왜곡을 유발하는 실재하는 문제임을 입증했습니다. Li et al. (2024)[4]은 벤치마크

유출률이 1%에서 최대 45%에 달하며 이로 인해 일부 모델의 성능이 최대 14%까지 과대평가될 수 있음을 밝혔습니다. Kocyigit et al. (2025)[5] 또한 기계 번역(MT) 태스크에서 테스트셋이 훈련 데이터에 포함될 경우 BLEU 점수가 최대 30점까지 비정상적으로 상승하는 현상을 정량화했습니다.

이러한 문제는 특정 도메인에서 더욱 심각하게 나타납니다. Zhou et al. (2025)[6]은 83개의 소프트웨어 엔지니어링(SE) 벤치마크를 분석하여, QuixBugs (100%), BigCloneBench (55.7%) 등 일부 벤치마크가 극심하게 유출되었음을 발견하고, 유출 데이터를 정제한 LessLeak-Bench를 제안했습니다.

데이터 유출 문제의 심각성이 대두되면서, 이를 탐지하고 완화하려는 방법론적 연구 또한 주목받고 있습니다. Hidayat et al. (2025)[7]은 N-gram 기반 탐지법이 가장 안정적인 누출 탐지 성능을 보임을 시뮬레이션을 통해 입증했습니다. Cheng et al. (2025)[8]의 서베이 논문은 이러한 유출의 정의, 영향, 탐지 기법 및 완화 전략을 포괄적으로 검토하며 해당 분야의 중요성을 강조하고 있습니다.

선행 연구들이 데이터 유출을 탐지하고 새로운 데이터셋을 구축하는 대신 우리는 유출을 '제거'하는 대신, 모델이 벤치마크 데이터를 학습했을 가능성을 적극적으로 활용합니다. 즉, 본 연구는 의도적인 데이터 교란을 통해, 이미 널리 퍼져 학습되었을 수 있는 표준 데이터 벤치마크를 모델의 강건성을 진단하는 도구로 재활용합니다. 이 방법론은 데이터를 교란시켜 모델이 원본 데이터를 학습했는지 아니면 이해했는지 판별하며, 교란된 데이터셋으로의 재평가를 통해 모델의 진정한 일반화 수준을 측정하는 방법을 제시합니다.

III. 방법론

본 연구의 핵심 방법론은 원본 벤치마크 데이터셋을 활용하여 병치되는 교란 데이터셋(Perturbed Dataset)을 구축하는 것입니다. 이 교란 데이터셋은 모델이 데이터를 학습했는지, 혹은 내재된 의미를 이해했는지를 판별하기 위해 의도적으로 구축되었습니다. 교란 전략은 데이터의 유형에 따라 두 가지 주요 방식으로 적용되었습니다: (1) 의미는 보존하되 표현은 바꾸는 텍스트 콘텐츠 교란, (2) 데이터의 스키마와 레이블을 변경하는 구조적 및 레이블 교란으로 구성됩니다.

3.1 텍스트 콘텐츠 교란

우리는 NLTK 라이브러리와 WordNet 시소러스를 활용하여 의미 보존 동의어 치환을 수행했습니다. 이

프로세스는 다음과 같습니다:

1. 품사 태깅(POS Tagging): nltk.pos_tag를 사용해 입력 텍스트의 모든 단어를 토큰화하고 품사를 식별합니다.
2. 교체 대상 선정: 의미에 핵심적인 영향을 미치는 주요 품사, 즉 명사(Noun), 동사(Verb), 형용사(Adjective), 부사(Adverb)만을 교체 대상으로 한정합니다.
3. 동의어 탐색: WordNet에서 해당 단어의 품사에 맞는 동의어 집합을 조회합니다.
4. 무작위 교체: 식별된 교체 대상 단어 중 50%의 비율을 무작위로 선정하여 적절한 동의어로 교체합니다.

3.2 구조적 및 레이블 교란

콘텐츠 교란과 더불어, 모델이 프롬프트의 특정 구조나 키워드 자체를 학습했는지 확인하기 위해 데이터의 메타 정보를 수정했습니다. 이 교란은 텍스트와 정형 데이터셋 모두에 적용되었습니다.

1. 특성명 변경: 모델이 특정 특성 이름과 값의 연관성을 학습했는지 테스트하기 위해, 데이터 유형에 관계없이 입력 특성의 이름을 변경했습니다. 전체 변경 목록은 아래 Table 1와 같습니다.

데이터셋	원본 특성명	교란 특성명
AG News	'article_text'	'article_content'
IMDb	'text'	'review_content'
SST-2	'sentence'	'review_text'
DBpedia-14	'content'	'entry_text'
Titanic	'pclass', 'sex', 'age', 'sibsp', 'parch',...	'TicketClass', 'Gender', 'PassengerAge', 'FamilySize_SibSp',...

Table 1. 특성명 변경 목록

2. 레이블 클래스명 변경: 모델이 특정 입력에 대해 출력 레이블 문자열 자체를 학습했는지 확인하기 위해, 모든 데이터셋의 타겟 레이블 이름을 의미는 유사하지만 표현이 다른 단어로 변경했습니다. 전체 변경 목록은 아래 Table 2와 같습니다.

데이터셋	원본 레이블	교란 레이블
AG News	'Positive', 'Negative'	'Good Review', 'Bad Review'
IMDb	'Positive', 'Negative'	'Good', 'Bad'
SST-2	'World', 'Sports', 'Business', 'Sci/Tech'	'Global', 'Athletics', 'Commerce', 'Tech/Sci'
DBpedia-14	'Company', 'EducationalInstitution', 'Artist', 'Athlete',...	'Org', 'School', 'Person', 'Player', 'Official', 'Transport',...
Titanic	'Survived', 'Not'	'Lived', 'Perished'

	Survived'	
--	-----------	--

Table 2. 레이블명 변경 목록

이러한 교란을 통해 생성된 교란 데이터셋은 원본과 동일한 내재적 난이도를 가지지만, 표면적 형태는 완전히 달라집니다. 따라서 원본 데이터셋과 교란 데이터셋 간의 성능 차이는 모델의 일반화 능력과 학습 의존도를 측정하는 직접적인 지표로 활용될 수 있습니다.

IV. 실험 및 평가

4.1 실험 구성

본 연구는 인-컨텍스트 러닝(ICL) 성능 평가를 위해 세 가지 sLLM을 선정하고 벤치마크 데이터셋을 원본 및 교란 버전으로 구성하여 평가를 진행했습니다. 평가 대상 모델은 Google의 google/gemma-3-4b-it[1], Alibaba의 Qwen/Qwen2.5-3B-Instruct[3], Meta의 meta-llama/Llama-3.2-3B-Instruct[2]로, 모두 사전 학습된 상태로 사용되었으며, 프롬프트의 경우 Kim et al. (2025)[9]의 구조화된 프롬프트 구성을 통해 분류 태스크를 수행했습니다.

모델명 \ 데이터셋	Qwen2.5-3B-Instruct	gemma-3-4b-it	Llama-3.2-3B-Instruct
AG News	0.6551	0.6033	0.5568
AG News(P)	0.6761	0.6130	0.3653
IMDb	0.9038	0.9830	0.9388
IMDb(P)	0.9542	0.9840	0.6640
SST-2	0.8459	0.6773	0.6277
SST-2(P)	0.5644	0.7311	0.6739
DBpedia-14	0.9039	0.9135	0.9042
DBpedia-14(P)	0.9000	0.9127	0.8824
Titanic	0.6483	0.6465	0.6470
Titanic(P)	0.6525	0.4082	0.4633

Table 3. 데이터셋별 정확도(Acc) 비교, (P)는 교란 데이터를 의미합니다.




Figure 1. 데이터셋별 Acc 증감률 비교

3.2 교란 여부에 따른 결과 분석

본 연구의 핵심인 교란 결과 분석은 원본 데이터셋 대비 교란 데이터셋에서 발생하는 성능 변화를 측정합니다. Figure 1은 각 모델이 원본 벤치마크 정확도 대비, 교란 벤치마크에서 기록한 정확도 변화율(%)을 나타냅니다. 음수 값은 성능 하락을 의미합니다.

Llama-3.2-3B[2] 모델은 학습 데이터 유출 취약성을 극명하게 보였습니다. 특히 AG News(-34.40%)와 IMDb(-29.26%) 데이터에서 매우 심각한 성능 하락을 기록했는데, 이는 텍스트 내용 교란이 적용되었을 때 모델이 원본 데이터의 표면적 정보를 강하게 재현하거나 학습에 사용된 가능성을 보여줍니다. 이 모델이 보였던 높은 점수는 실제 의미 이해 능력보다는 학습에 사용된 데이터의 패턴에 기인한 것일 수 있으며, 모델의 일반화 능력을 잘못 반영하고 있음을 시사합니다.

Qwen2.5-3B[3] 모델 역시 특정 데이터에 대한 학습 의존도가 높았습니다. SST-2 데이터셋에서 -33.29%라는 가장 큰 하락을 기록했습니다. 이는 모델에 따라 학습 과정에서 특정 데이터를 학습했을 가능성을 보여주며, SST-2와 같이 짧은 문장 구조 및 이진 레이블 패턴을 가진 데이터셋에서 특히 이러한 의존도가 높아질 수 있음을 의미합니다.

Gemma-3-4b-it[1] 모델은 텍스트 교란에 대한 가장 우수한 강건성을 입증했습니다. 이 모델은 대부분의 텍스트 벤치마크(AG News, IMDb, DBpedia)에서 성능 변화가 거의 없거나 오히려 소폭 상승하는 안정적인 결과를 보였습니다. 이는 Gemma-3-4b-it[1]가 다른 모델들보다 데이터의 표면적 변화에 강건하며, 내재된 의미를 더 잘 이해하고 있음을 의미하며, 표준 벤치마크 점수가 실제 일반화 능력에 더 근접함을 시사합니다.

이러한 실험 결과를 바탕으로, 본 연구에서 제안하는 데이터 교란 기반 강건성 테스트는 기존 표준 벤치마크 데이터를 사용하여 LLM의 진정한 일반화 능력을 더욱 정확하고 신뢰성 있게 평가하는 데 필수적인 방법론임을 입증합니다.

V. 결론 및 향후 연구 방향

본 연구는 LLM의 평가 과정에서 발생하는 데이터 유출 문제를 분석하고, 데이터 교란 기반 강건성 평가 방법을 제안하였다. 실험 결과, 일부 모델은 교란 데이터에서 성능이 급격히 하락하여 학습 의존성이 드러난 반면, Gemma-3-4b-it 모델은 안정적인

성능을 유지하며 높은 일반화 능력을 보였다. 제안된 방법은 기존 벤치마크를 활용하면서도 모델의 일반화 성능과 유출 민감도를 진단할 수 있는 효율적 평가 도구로 활용 가능하다. 향후 연구에서는 교란 유형별 민감도 분석과 멀티모달 데이터 확장을 통해 평가 프레임워크의 범용성을 강화할 예정이다.

참고문헌

- [1] Team, Gemma, et al. "Gemma 3 technical report." arXiv preprint arXiv:2503.19786 (2025).
- [2] Dubey, Abhimanyu, et al. "The llama 3 herd of models." arXiv e-prints (2024): arXiv-2407.
- [3] Team, Qwen. "Qwen2 technical report." arXiv preprint arXiv:2407.10671 2.8 (2024).
- [4] Li, Yucheng, Frank Guerin, and Chenghua Lin. "An open source data contamination report for large language models." arXiv preprint arXiv:2310.17589 (2023).
- [5] Kocyigit, Muhammed Yusuf, et al. "Overestimation in LLM Evaluation: A Controlled Large-Scale Study on Data Contamination's Impact on Machine Translation." arXiv preprint arXiv:2501.18771 (2025).
- [6] Zhou, Xin, et al. "Lessleak-bench: A first investigation of data leakage in llms across 83 software engineering benchmarks." arXiv preprint arXiv:2502.06215 (2025).
- [7] Hidayat, Naila Shafirni, et al. "Simulating Training Data Leakage in Multiple-Choice Benchmarks for LLM Evaluation." arXiv preprint arXiv:2505.24263 (2025).
- [8] Cheng, Yuxing, Yi Chang, and Yuan Wu. "A survey on data contamination for large language models." arXiv preprint arXiv:2502.14425 (2025).
- [9] Kim, Minseo, et al. "Exploring Modular Prompt Design for Emotion and Mental Health Recognition." Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems. 2025.